


Sampling Representation & Monte Carlo Approximation in deep learning

소프트웨어 공대 강의

노기섭 교수

(kafa46@cju.ac.kr)

딥러닝 공부하다 보면 보게 되는 것들.....



일반적인 딥러닝 구조

$$\mathbb{E}_{X \sim P(X)}[f(x)] = \sum_{x \in \mathcal{X}} P(X = x) \cdot x$$



이건 또 뭐냐?

이번 강의를 들으면 확률 분포에서 샘플링 하는

표현법과 의미를 이해할 수 있게 됩니다^^

확률 분포로부터의 샘플링

■ Prerequisites

- Random variable (확률 변수) → <https://youtu.be/iTxTGBOhzCA>
 - Probability function (확률 함수)
 - Probability distribution (확률 분포)
- } <https://youtu.be/qpbIKg21mvI>

■ 샘플링(or dataset)에서 자주 사용하는 표현법

$X \sim P$ 또는 $X \sim P(X = x)$

Random variable X 는 확률 분포(확률 함수) $P(x)$ 와 같이 분포되어 있다.

Random variable X 는 확률 분포 $P(x)$ 에서 샘플링 하였다.

- 아래 수식을 보게 되었다면, 어떻게 해석할까요?

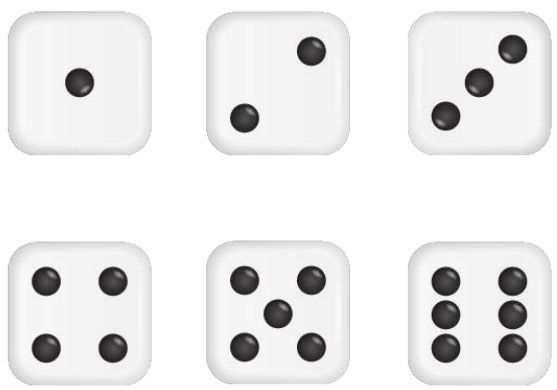
$$\mathbb{E}_{X \sim P(X)}[f(x)] = \sum_{x \in \mathcal{X}} P(X = x) \cdot x$$

다음 슬라이드에서
예제를 통해 살펴보겠습니다 ^^

Sample Space (Ω)가 명확한 경우(복습)

주사위 던지는 실험

- Random variable X : 주사위를 던졌을 때 나온 값



Ω	X	E
1	→	1
2	→	2
3	→	3
4	→	4
5	→	5
6	→	6

하지만 정확한
Sample space 모를 경우는?



딥러닝에 사용할 dataset일 경우와 동일...
몬테 카를로 근사부터 다음 슬라이드에서
예제를 통해 살펴보겠습니다 ^^

$$\mathbb{E}_{X \sim P(X)}[f(x)] = \sum_{x \in \mathcal{X}} P(X = x) \cdot f(x)$$

$$= \frac{1}{6} \cdot 1 + \frac{1}{6} \cdot 2 + \frac{1}{6} \cdot 3 + \frac{1}{6} \cdot 4 + \frac{1}{6} \cdot 5 + \frac{1}{6} \cdot 6 = \frac{21}{6} = 3.5$$

여기서 $f(x) = x$

Monte Carlo Approximation

■ Goal

Approximate $\mathbb{E}_{X \sim P(X)}[f(x)]$

**Intractable to compute
exactly in efficient way!!**

■ Definition

If $x_1, x_2, \dots, x_n \sim P(x)$ i.i.d. then

$$\hat{\mu}_n = \frac{1}{n} \sum_{i=1}^n f(x_i) \text{ is a basic Monte Carlo estimator}$$

of $\mathbb{E}_{X \sim P(X)}[f(x)]$

It is just a sample mean

■ Remarks

$$\mathbb{E}[\hat{\mu}_n] = \mathbb{E}[f(x)]$$

Unbiased estimator(샘플의 평균은 전체 평균과 같다.)

Consistent estimator(샘플이 많으면 오차가 적어진다.)

$$\hat{\mu}_n \xrightarrow{P(x)} \mathbb{E}[f(x)] \text{ as } n \rightarrow \infty \text{ (for all } \epsilon > 0, P(|\hat{\mu}_n - \mathbb{E}[f(x)]| < \epsilon) \rightarrow 1)$$

- 1940년대에 '존 폰 노이만'과 '스타니스라프 울람'에 의해 발명
 - 룰렛 게임과 동일한 무작위 특성을 공유한다는 점 때문에 모나코의 유명한 도박장의 이름을 따서 명명
- 자료출처: <https://aws.amazon.com/ko/what-is/monte-carlo-simulation/>




Example: Monte Carlo Approximation

■ 다음 도형의 넓이를 구해 주세요 ^^.

- 조건

- 데이터는 많이 구할 수 있다.
- 도형을 생성하는 함수 $f(x)$ 알 수 있다.
- 정확한 넓이는 존재할 것이다. 그러나 구하는 공식은 정확히 모른다.

- 해결책



- Random variable X 는 확률 분포(함수) $P(X)$ 를 따른다고 가정
- Random 데이터 n 개를 모은다.
- $f(x)$ 를 이용하여 n 개 데이터 중에서 도형 내부에 있는 개수를 센다.


- 도형의 면적 = $\frac{\text{도형 내부에 있는 데이터의 개수}}{\text{전체 데이터의 개수}} \times \text{직사각형 넓이}$

$$\mathbb{E}_{X \sim P(X)}[f(X)] \approx \frac{1}{n} \sum_{i=1}^n f(x_i), \text{ where } x_i \sim P(X)$$

실제 딥러닝 데이터는 어떻게 처리할까요?

parameter θ

$$\hat{\theta} = \operatorname{argmax}_{\theta \in \Theta} \mathbb{E}_{x \sim P(x)} [\log P(y|x; \theta)]$$



$$\mathcal{D} = \{(x_i, y_i)\}_{i=1}^n$$

Monte Carlo Approx.

$$\hat{\theta} = \operatorname{argmax}_{\theta \in \Theta} \frac{1}{n} \sum_{i=1}^n \log P(y_i|x_i; \theta)$$

$$\hat{\theta} = -\operatorname{argmin}_{\theta \in \Theta} \frac{1}{n} \sum_{i=1}^n \log P(y_i|x_i; \theta)$$

	carat	cut	color	clarity	depth	table	price
1	0.52	Ideal	D	VS2	61.4	56	1664
2	0.5	Very Good	F	SI1	62.3	60	1250
3	0.61	Ideal	G	VVS2	61.6	54	2242
4	0.36	Premium	G	VS2	62.5	58	756
5	0.7	Very Good	E	VS2	63.5	54	2889
6	0.56	Ideal	F	VS1	61.7	56	2016
7	1.19	Premium	E	I1	60.2	61	3572
8	0.52	Ideal	F	IF	60.6	57	2575
9	0.38	Ideal	E	IF	62.7	55	1433
10	0.51	Ideal	E	VS2	62.1	54	1608

References

■ 참고 자료

- Monte Carlo Approximation (몬테 카를로 근사)
 - 이론: <https://www.youtube.com/watch?v=7TybpwBlcMk&t=8s>
 - 실습: https://youtu.be/x3b_DAEmZnU?si=M074vK5Tz_XAWuSf
- Standard notation for [sampling from] a conditional probability (조건부 확률에서의 샘플링 표기)
 - <https://stats.stackexchange.com/questions/179182/standard-notation-for-sampling-from-a-conditional-probability>



수고하셨습니다 ..^^..