#### Differentiation

Back-propagation (역전파 학습)

소프트웨어 꼰대 강의

노기섭 교수


(<u>kafa46@cju.ac.kr</u>)

#### Course Overview


Topic	Contents
01. Orientation	Course introduction, motivations, final objectives
오리엔테이션	과정 소개, 동기부여, 최종 목표
02. Learning in deeplearning	How does the deeplearing learns knowledge from data
딥러닝 학습	어떻게 딥러닝은 데이터로부터 지식을 배우는가?
03. Principle of differentiation	Basics of differentiation (concepts, notation, operations)
미분의 원리	미분 기본지식 (개념, 표기, 연산)
04. Partial differentiation	Concept & operation of partial differenciation
편미분	편미분 개념, 연산
05. Gradient descent	Concept, interpretation and learning in gradient descent
경사 하강법	경사하강 알고리즘 개념, 해석 및 학습
06. Chain rule	Concept & operation of chain rule
연쇄법칙	연쇄법칙 개념 및 연산
07. Matrix differentiation	Partial differentiation in linear system
행렬미분	선형시스템에서의 편미분
08. Back propagation	The mechanism of back propagation
역전파 학습	역전파 학습의 작동 방법
09. Gradient vanishing 기울기 소실	Quick overview on activation function, cause root of gradient vanishing and its counter-measure 활성함수 간단 소개, 기울기 소실 근본원인과 대책

#### The Last Puzzle in Deep Learning

# 머신러닝(딥러닝)




#### Back-propagation, 간략하게 정리하기 (1/7)



업데이트 규칙 
$$W = W - \alpha \frac{\partial L(\theta)}{\partial W}$$


$$\frac{\partial L( heta)}{\partial W_{out}^T}$$
 구하기  $\;\;\; 
ightharpoons \;\;\; W_{out}^T$  업데이트

# Back-propagation, 간략하게 정리하기 (2/7)




$$W = W - lpha rac{\partial L( heta)}{\partial W}$$

# Back-propagation, 간략하게 정리하기 (3/7)




업데이트 규칙
$$W=W-lpharac{\partial L( heta)}{\partial W}$$

## Back-propagation, 간략하게 정리하기 (4/7)




업데이트 규칙 
$$W = W - \alpha \frac{\partial L(\theta)}{\partial W}$$

# Back-propagation, 간략하게 정리하기 (5/7)



업데이트 규칙
$$W = W - \alpha \frac{\partial L(\theta)}{\partial W}$$

# Back-propagation, 간략하게 정리하기 (6/7)



업데이트 규칙
$$W = W - \alpha \frac{\partial L(\theta)}{\partial W}$$

Back propagation 완료




다시 전진 학습 Feed forward



다시 오차 계산 Compute Loss  $L(\theta)$ 

# Back-propagation, 간략하게 정리하기 (7/7)



비선형 학습을 위한 활성함수(activation function), bias, 출력 계층에 사용되는 softmax 등을 고려하면 미분은 더 복잡해 진다.



계산량이 엄청 많아질 것은 확실하다



Dynamic Programming Algorithm + Chain Rule 적용으로 해결

#### Chain Rule + DP Algorithm

#### **Dynamic Programming Algorithm**

미분 값 구하기

$$\frac{\partial L(\theta)}{\partial W_{out}^T} = \frac{\partial L(\theta)}{\partial \hat{v}} \times \frac{\partial \hat{y}}{\partial W_{out}^T}$$

$$\frac{\partial L(\theta)}{\partial W_3^T} = \frac{\partial L(\theta)}{\partial \hat{y}} \times \frac{\partial \hat{y}}{\partial W_{out}^T} \times \frac{\partial W_{out}^T}{\partial W_3^T}$$

$$\frac{\partial L(\theta)}{\partial W_2^T} = \frac{\partial L(\theta)}{\partial \hat{y}} \times \frac{\partial \hat{y}}{\partial W_{out}^T} \times \frac{\partial W_{out}^T}{\partial W_3^T} \times \frac{\partial W_3^T}{\partial W_2^T}$$

$$\frac{\partial L(\theta)}{\partial W_1^T} = \frac{\partial L(\theta)}{\partial \hat{y}} \times \frac{\partial \hat{y}}{\partial W_{out}^T} \times \frac{\partial W_{out}^T}{\partial W_3^T} \times \frac{\partial W_3^T}{\partial W_2^T} \times \frac{\partial W_2^T}{\partial W_1^T}$$

조건

1. 반복적인 부분 문제의 존재


(Repeated subproblem)

2. 부분 최적해 (Sub optimal)

작은 문제의 결과를 저장하여 큰 문제를 풀 때 사용

## Toy Example: DP를 컴퓨터로 구현하면? (1/4)


Simple Neural Networks



자료출처: https://blog.paperspace.com/pytorch-101understanding-graphs-and-automatic-differentiation/


## Toy Example: DP를 컴퓨터로 구현하면? (1/4)

Generation of Computational Graph



사료술서: https://blog.paperspace.com/pytorch-101understanding-graphs-and-automatic-differentiation/

## Toy Example: DP를 컴퓨터로 구현하면? (3/4)




진입 간선의 가중치 활용

자료출처: https://blog.paperspace.com/pytorch-101understanding-graphs-and-automatic-differentiation/

#### Toy Example: DP를 컴퓨터로 구현하면? (4/4)

임의의 노드에 대한 편미분 값 구하기



자료출처: https://blog.paperspace.com/pytorch-101understanding-graphs-and-automatic-differentiation/

#### Chain Rule 구현 - PyTorch

#### 거의 모든 딥러닝 구조가 유사합니다. ^^ Chain Rule, DP Algrithm, Gradient Descent 이해가고 있다면, 모든 코드를 완벽히 이해 가능!

```
import torch
from torchvision.models import resnet18,
ResNet18 Weights
model = resnet18(
   weights=ResNet18 Weights.DEFAULT
data = torch.rand(1, 3, 64, 64)
labels = torch.rand(1, 1000)
prediction = model(data) # forward pass
loss = (prediction - labels).sum()
loss.backward() # backward pass
optim = torch.optim.SGD(
   model.parameters(),
   lr=1e-2,
   momentum=0.9
optim.step() # gradient descent
```

모델의 예측값과 그에 해당하는 정답(label)을 사용하여 오차(error, 손실, loss) 계산

신경망을 통해 에러를 역전파 수행 오차 텐서(error tensor)에 .backward()를 호출 하면 pytorch가 자동으로 수행

Autograd가 매개변수(parameter)의 .grad 속성 (attribute)에, 모델의 모든 매개변수에 대한 미분값(gradient)을 계산하고 저장

저장된 값을 활용하여 모든 파라미터 업데이트



수고하셨습니다 ..^^..